Các loại bộ nhớ trong CUDA

Trần Trung Kiên
ttkien@fit.hcmus.edu.vn

Cập nhật lần cuối: 17/11/2021

KHOA CÔNG NGHỆ THÔNG TIN
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

fit@hcmus

Tổng thể

- Bộ nhớ toàn cục — đọc/ghi ↔ — grid
- Bộ nhớ hằng — đọc → — grid
- Bộ nhớ chia sẻ — đọc/ghi ↔ — block
- Bộ nhớ thanh ghi & cục bộ — đọc/ghi ↔ — thread

Bộ nhớ toàn cục (GMEM)

- Khi host dùng hàm `cudaMalloc` để cấp phát vùng nhớ ở device, vùng nhớ này sẽ nằm ở **bộ nhớ toàn cục (GMEM – global memory)** của device
- GMEM là nơi host giao tiếp (chép dữ liệu sang và lấy kết quả về) với device
- GMEM nằm ở DRAM và là bộ nhớ có dung lượng lớn nhất ở device

  Truy vấn: `totalGlobalMem` trong struct `cudaDeviceProp`
- Nhưng ở device, GMEM là bộ nhớ có tốc độ truy xuất chậm

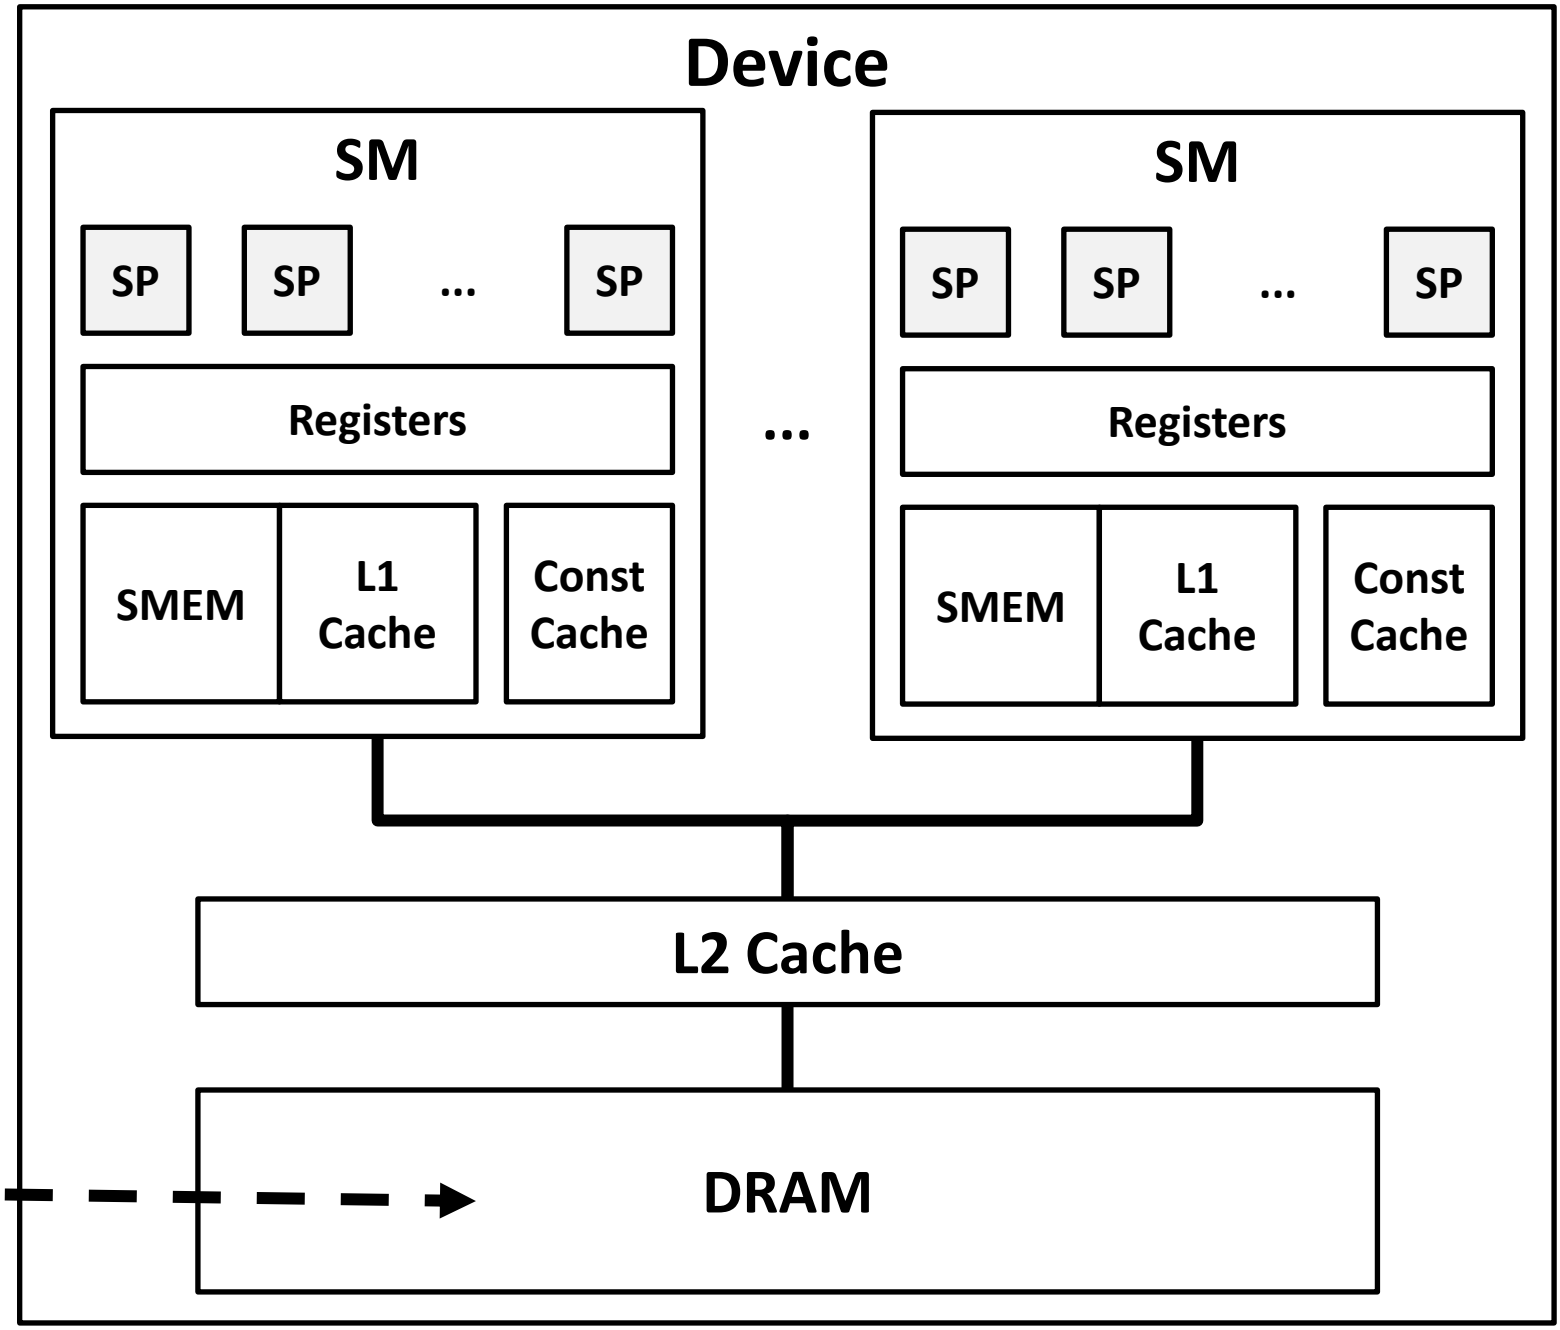
Device
SM
SP
SP
...
SP
Registers
SMEM
L1 Cache
Const Cache
...
SM
SP
SP
...
SP
Registers
SMEM
L1 Cache
Const Cache
L2 Cache
DRAM
Bộ nhớ toàn cục

Bộ nhớ toàn cục (GMEM)

- Khi host dùng hàm `cudaMalloc` để cấp phát vùng nhớ ở device, vùng nhớ này sẽ nằm ở **bộ nhớ toàn cục (GMEM – global memory)** của device
- GMEM là nơi host giao tiếp (chép dữ liệu sang và lấy kết quả về) với device
- GMEM nằm ở DRAM và là bộ nhớ có dung lượng lớn nhất ở device

  Truy vấn: `totalGlobalMem` trong struct `cudaDeviceProp`
- Nhưng ở device, GMEM là bộ nhớ có tốc độ truy xuất chậm

  → nên tìm cách hạn chế số lần các thread truy xuất GMEM (đây là mục đích của việc sử dụng các loại bộ nhớ khác)

Bộ nhớ toàn cục (GMEM)

Ta có thể cấp phát vùng nhớ ở GMEM bằng hàm `cudaMalloc`

- Host có thể đọc/ghi vùng nhớ này bằng hàm `cudaMemcpy`
- Con trỏ trỏ tới vùng nhớ này được host truyền vào tham số của hàm kernel
- Trong hàm kernel, các thread đều có thể truy xuất đến vùng nhớ này thông qua con trỏ được truyền vào
- Vùng nhớ này sẽ được giải phóng khi host gọi hàm `cudaFree`

Bộ nhớ toàn cục (GMEM)

Ta cũng có thể khai báo tĩnh biến ở GMEM với từ khóa `__device__`

- Vd, `__device__ float a[10];`
- Câu lệnh khai báo phải được đặt ngoài tất cả các hàm
- Host có thể đọc/ghi biến này bằng hàm `cudaMemcpyFrom/ToSymbol`
- Trong hàm kernel, các thread đều có thể truy xuất đến biến này mà không cần dùng phương pháp truyền tham số vào hàm kernel
- Biến này sẽ được tự động giải phóng khi chương trình chạy xong

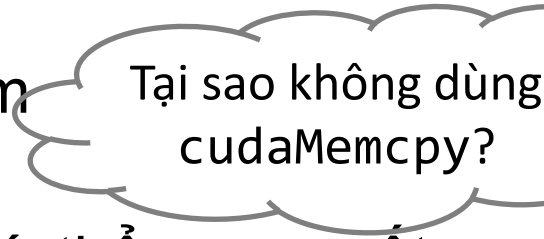

Bộ nhớ hằng (CMEM)

- Ngoài GMEM, host cũng có thể giao tiếp với device thông qua **bộ nhớ hằng (CMEM - constant memory)**
- Khi nào thì nên dùng CMEM?
  - Khi host muốn truyền cho device dữ liệu mà không thay đổi trong quá trình thực thi hàm kernel
  - Dữ liệu này cũng phải nhỏ vì CMEM chỉ có 64 KB
    - Truy vấn: `totalConstMem` trong struct `cudaDeviceProp`
  - Các thread trong warp cùng đọc một dữ liệu chung
    - CMEM cũng nằm ở DRAM giống GMEM, nhưng có bộ nhớ **Const Cache** ở các SM (8 KB / SM với hầu hết các CC)

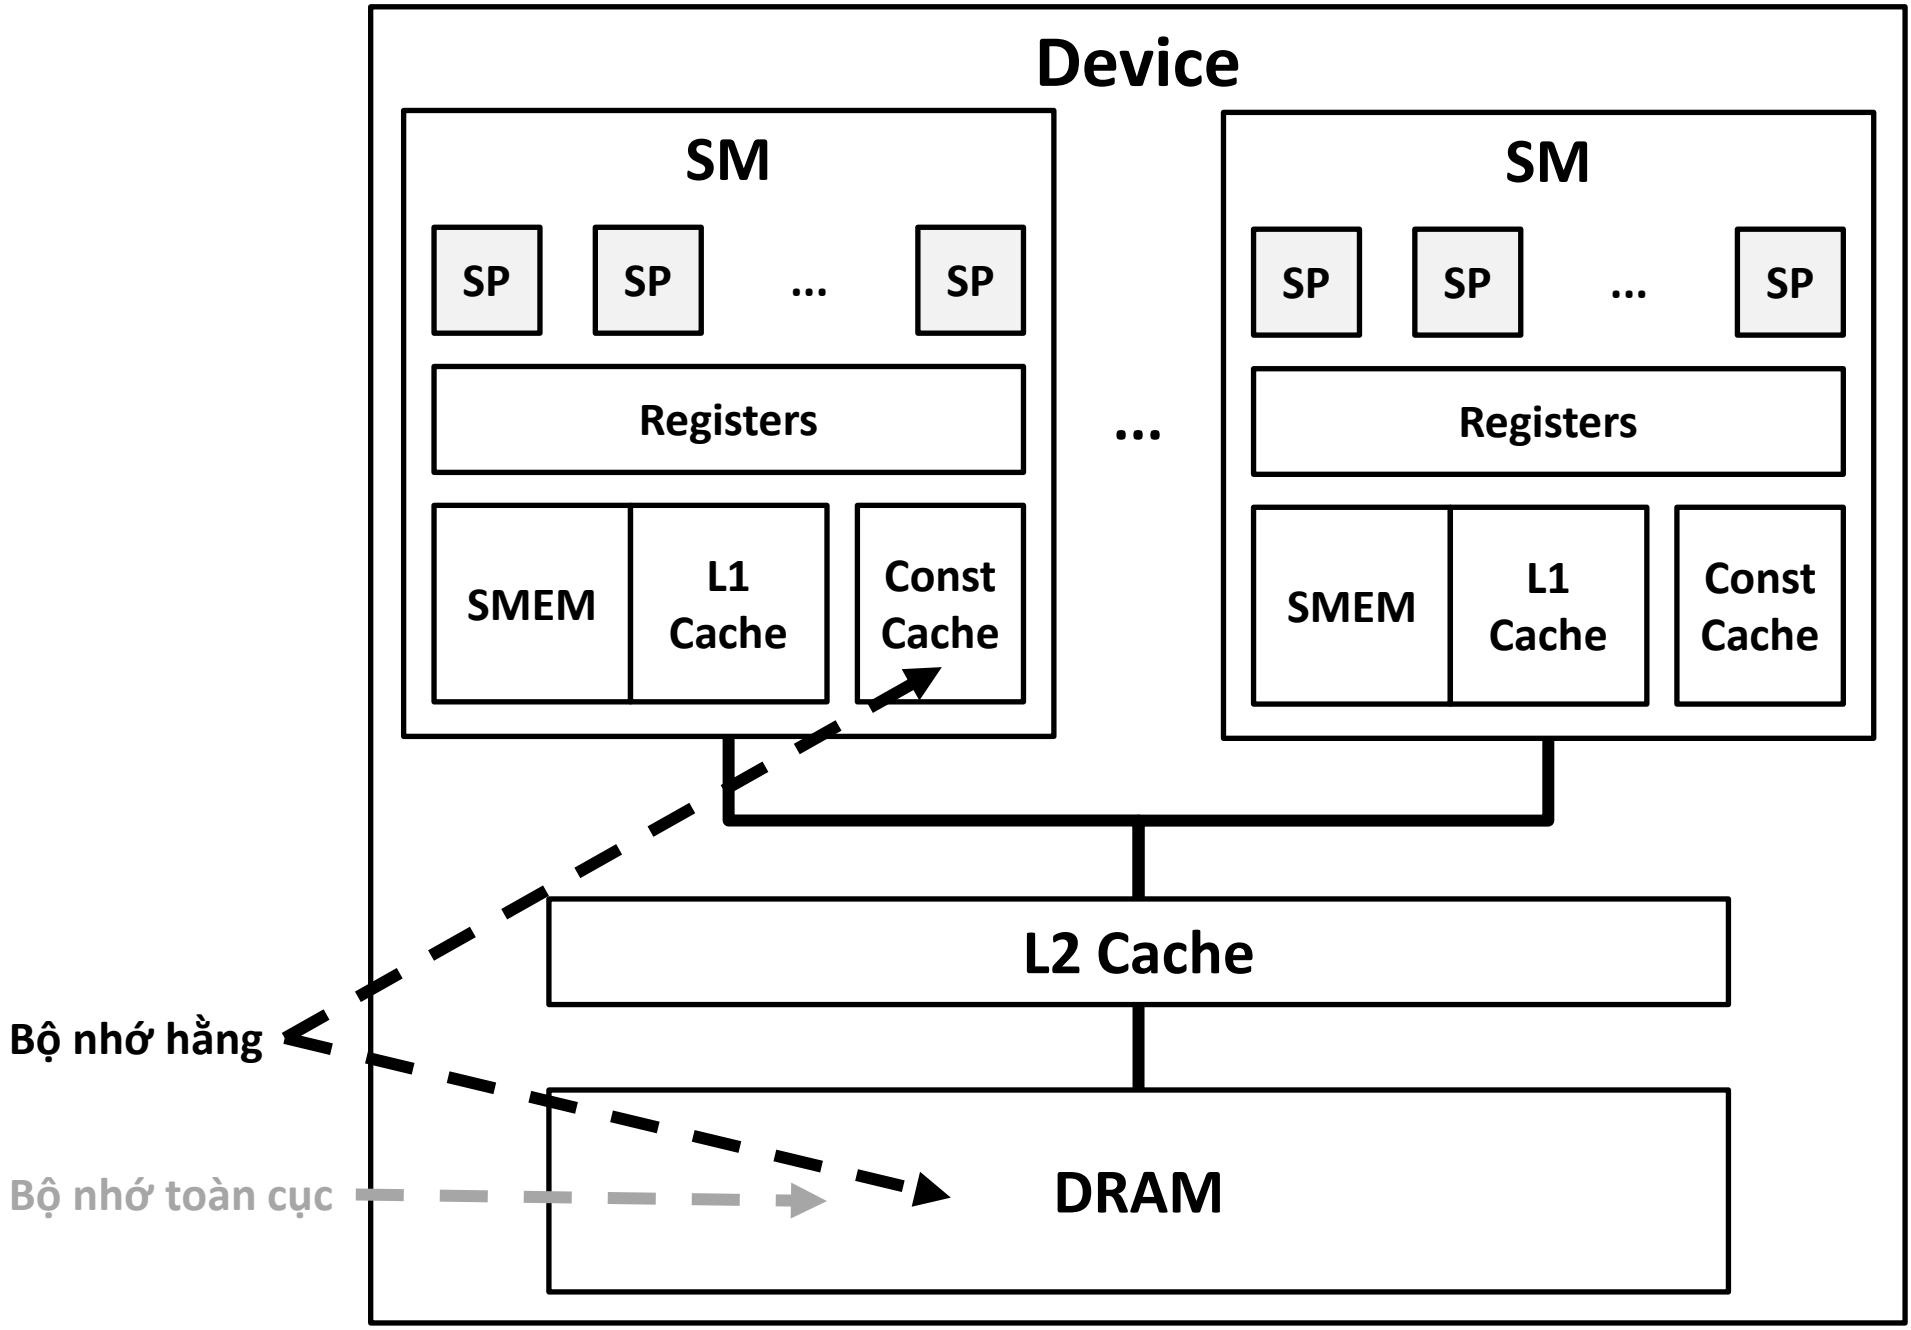
Device
SM
SP
SP
...
SP
Registers
SMEM
L1 Cache
Const Cache
...
SM
SP
SP
...
SP
Registers
SMEM
L1 Cache
Const Cache
L2 Cache
DRAM
Bộ nhớ hằng
Bộ nhớ toàn cục

Bộ nhớ hằng (CMEM)

- Ngoài GMEM, host cũng có thể giao tiếp với device thông qua **bộ nhớ hằng (CMEM - constant memory)**
- Khi nào thì nên dùng CMEM?
  - Khi host muốn truyền cho device dữ liệu mà không thay đổi trong quá trình thực thi hàm kernel
  - Dữ liệu này cũng phải nhỏ vì CMEM chỉ có 64 KB
    - Truy vấn: `totalConstMem` trong struct `cudaDeviceProp`
  - Các thread trong warp cùng đọc một dữ liệu chung
    - CMEM cũng nằm ở DRAM giống GMEM, nhưng có bộ nhớ **Const Cache** ở các SM (8 KB / SM với hầu hết các CC)
    - Const Cache có độ trễ thấp, nhưng lại có băng thông thấp (4B / clock cycle / SM)

      → nếu các thread trong warp cùng đọc một phần tử 4B thì chỉ tốn một lần đọc và dữ liệu đọc được sẽ được "broadcast" cho các thread trong warp, ngược lại sẽ tốn nhiều lần đọc

Bộ nhớ hằng (CMEM)

- Ở device, các tham số của hàm kernel được lưu ở CMEM
- Các khai báo biến ở CMEM: tương tự như cách khai báo tĩnh biến ở GMEM, nhưng thay từ khóa `__device__` bằng `__constant__`
  - Vd, `__constant__ float a[10];`
  - Câu lệnh khai báo phải được đặt ngoài tất cả các hàm
  - Host có thể đọc/ghi biến này bằng hàm `cudaMemcpyFrom/ToSymbol`
  - Trong hàm kernel, các thread đều có thể đọc (không ghi) biến này mà không cần dùng phương pháp truyền tham số vào hàm kernel
  - Biến này sẽ được tự động giải phóng khi chương trình chạy xong

Ví dụ: tính tích chập một chiều

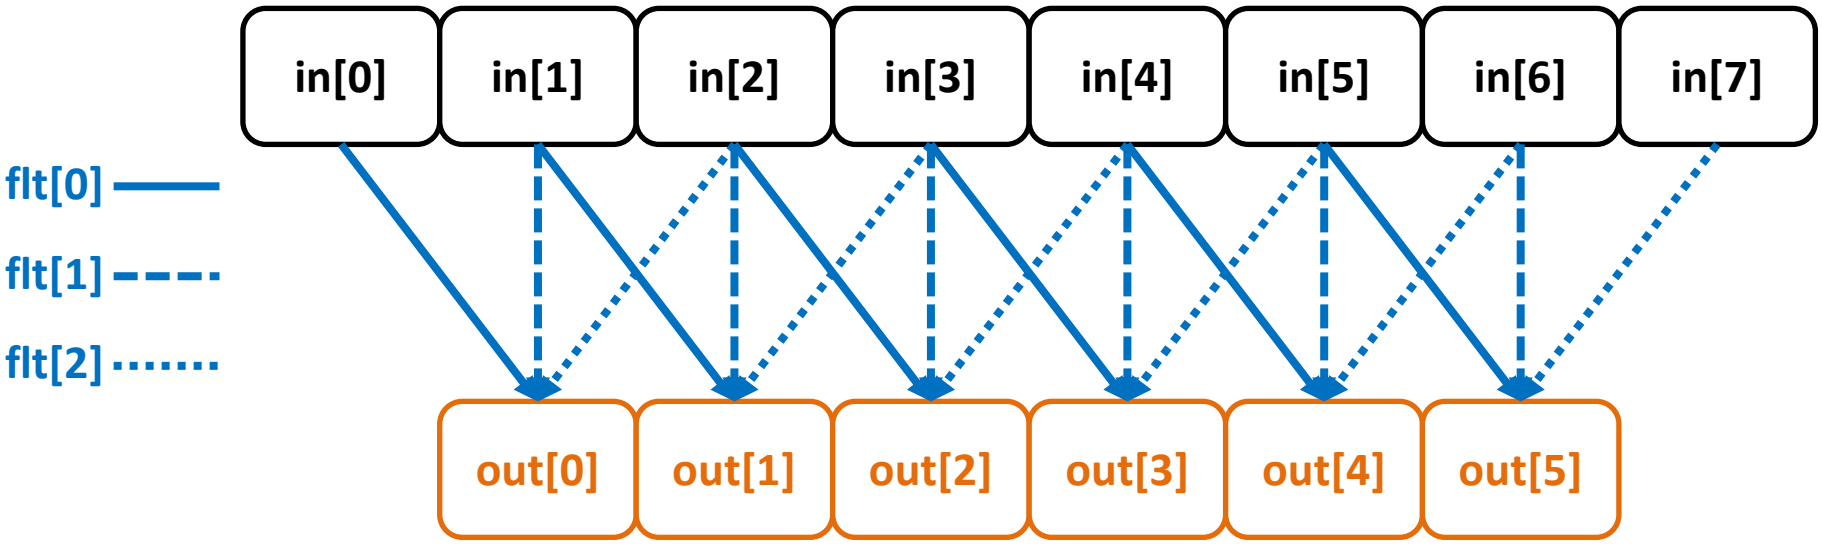

out[0] = in[0] * flt[0] + in[1] * flt[1] + in[2] * flt[2]
out[1] = in[1] * flt[0] + in[2] * flt[1] + in[3] * flt[2]
out[2] = in[2] * flt[0] + in[3] * flt[1] + in[4] * flt[2]
...

ni = 8
nf = 3
no = ?

```
#define NF 100
#define NI (1<<24)
#define NO (NI - NF + 1)
__constant__ float d_flt[NF];
…
int main(int argc, char *argv[])
{
    // Allocate memories for input, filter, output; set up data for input, filter
    float *in, *flt , *out;
    …
    // Allocate device memories
    float *d_in, *d_out;
    cudaMalloc(&d_in, NI * sizeof(float));
    cudaMalloc(&d_out, NO * sizeof(float));
    // Copy data from host memories to device memories
    cudaMemcpy(d_in, in, NI * sizeof(float), cudaMemcpyHostToDevice);
    cudaMemcpy(d_flt, flt, NF * sizeof(float), cudaMemcpyHostToDevice);
    cudaMemcpyToSymbol(d_flt, flt, NF * sizeof(float));
    // Launch the kernel
    …
    // Copy results from device memory to host memory
    cudaMemcpy(out, d_out, NO * sizeof(float), cudaMemcpyDeviceToHost);
    // Free device memories
    cudaFree(d_in);
    cudaFree(d_out);
    …
}
```

```
__global__ void convOnDevice(float *d_in, float *d_out)
{
        int i = blockIdx.x * blockDim.x + threadIdx.x;

        if (i < NO)
        {
                float s = 0;
                for (int j = 0; j < NF; j++)
                {
                        s += d_flt[j] * d_in[  ?  ];
                }
                d_out[i] = s;
        }
}
```

```
#define NF 100
#define NI (1<<24)
#define NO (NI - NF + 1)
__constant__ float d_flt[NF];
…
int main(int argc, char *argv[])
{
        …
        // Launch the kernel
        dim3 blockSize(512);
        dim3 gridSize((NO - 1) / blockSize.x + 1);
        convOnDevice<<<gridSize, blockSize>>>(d_in, d_out);
        …
}
```

```
__global__ void convOnDevice(float *d_in, float *d_out)
{
        int i = blockIdx.x * blockDim.x + threadIdx.x;

        if (i < NO)
        {
                float s = 0;
                for (int j = 0; j < NF; j++)
                {
                        s += d_flt[j] * d_in[i + j];
                }
                d_out[i] = s;
        }
}
```

```
#define NF 100
#define NI (1<<24)
#define NO (NI - NF + 1)
__constant__ float d_flt[NF];
…
int main(int argc, char *argv[])
{
        …
        // Launch the kernel
        dim3 blockSize(512);
        dim3 gridSize((NO - 1) / blockSize.x + 1);
        convOnDevice<<<gridSize, blockSize>>>(d_in, d_out);
        …
}
```

Thí nghiệm

- Kích thước mảng đầu vào: 2^{14}
- Phát sinh ngẫu nhiên giá trị số thực trong [0, 1] cho mảng đầu vào và bộ lọc
- GPU: GeForce GTX 560 Ti (CC 2.1)
- So sánh thời gian chạy của hàm kernel (block size 512) khi lưu bộ lọc ở CMEM với khi lưu bộ lọc ở GMEM
  - CMEM: 17.513 ms
  - GMEM: 25.099 ms

Bộ nhớ thanh ghi (RMEM)

Ngoài CMEM với cơ chế cache, ta cũng có thể làm giảm số lần truy xuất DRAM bằng **bộ nhớ thanh ghi (RMEM – Registers)**

```
__global__ void convOnDevice(float *d_in, float *d_out)
{
	int i = blockIdx.x * blockDim.x + threadIdx.x;

	if (i < NO)
	{
		float s = 0;
		for (int j = 0; j < NF; j++)
		{
			s += d_flt[j] * d_in[i + j];
		}
		d_out[i] = s;
	}
}
```

Thời gian chạy: 17.513

Bộ nhớ thanh ghi (RMEM)

Ngoài CMEM với cơ chế cache, ta cũng có thể làm giảm số lần truy xuất DRAM bằng **bộ nhớ thanh ghi (RMEM – Registers)**

```
__global__ void convOnDevice(float *d_in, float *d_out)
{
    int i = blockIdx.x * blockDim.x + threadIdx.x;

    if (i < NO)
    {
        float s = 0;
        d_out[i] = 0;
        for (int j = 0; j < NF; j++)
        {
            s += d_flt[j] * d_in[i + j];
            d_out[i] += d_flt[j] * d_in[i + j];
        }
        d_out[i] = s;
    }
}
```

Thời gian chạy: ~~17.513~~ 47.107

Bộ nhớ thanh ghi (RMEM)

Ngoài CMEM với cơ chế cache, ta cũng có thể làm giảm số lần truy xuất DRAM bằng **bộ nhớ thanh ghi (RMEM – Registers)**

```
__global__ void convOnDevice(float *d_ir
{
    int i = blockIdx.x * blockDim.x + threa

    if (i < NO)
    {
        float s = 0;
        d_out[i] = 0;
        for (int j = 0; j < NF; j++)
        {
            s += d_flt[j] * d_in[i + j];
            d_out[i] += d_flt[j] * d_in[i + j];
        }
        d_out[i] = s;
    }
}
```

- Mỗi thread sẽ có một phiên bản riêng của biến s và được lưu ở RMEM của thread đó
- RMEM là bộ nhớ có tốc độ truy xuất nhanh nhất ở device

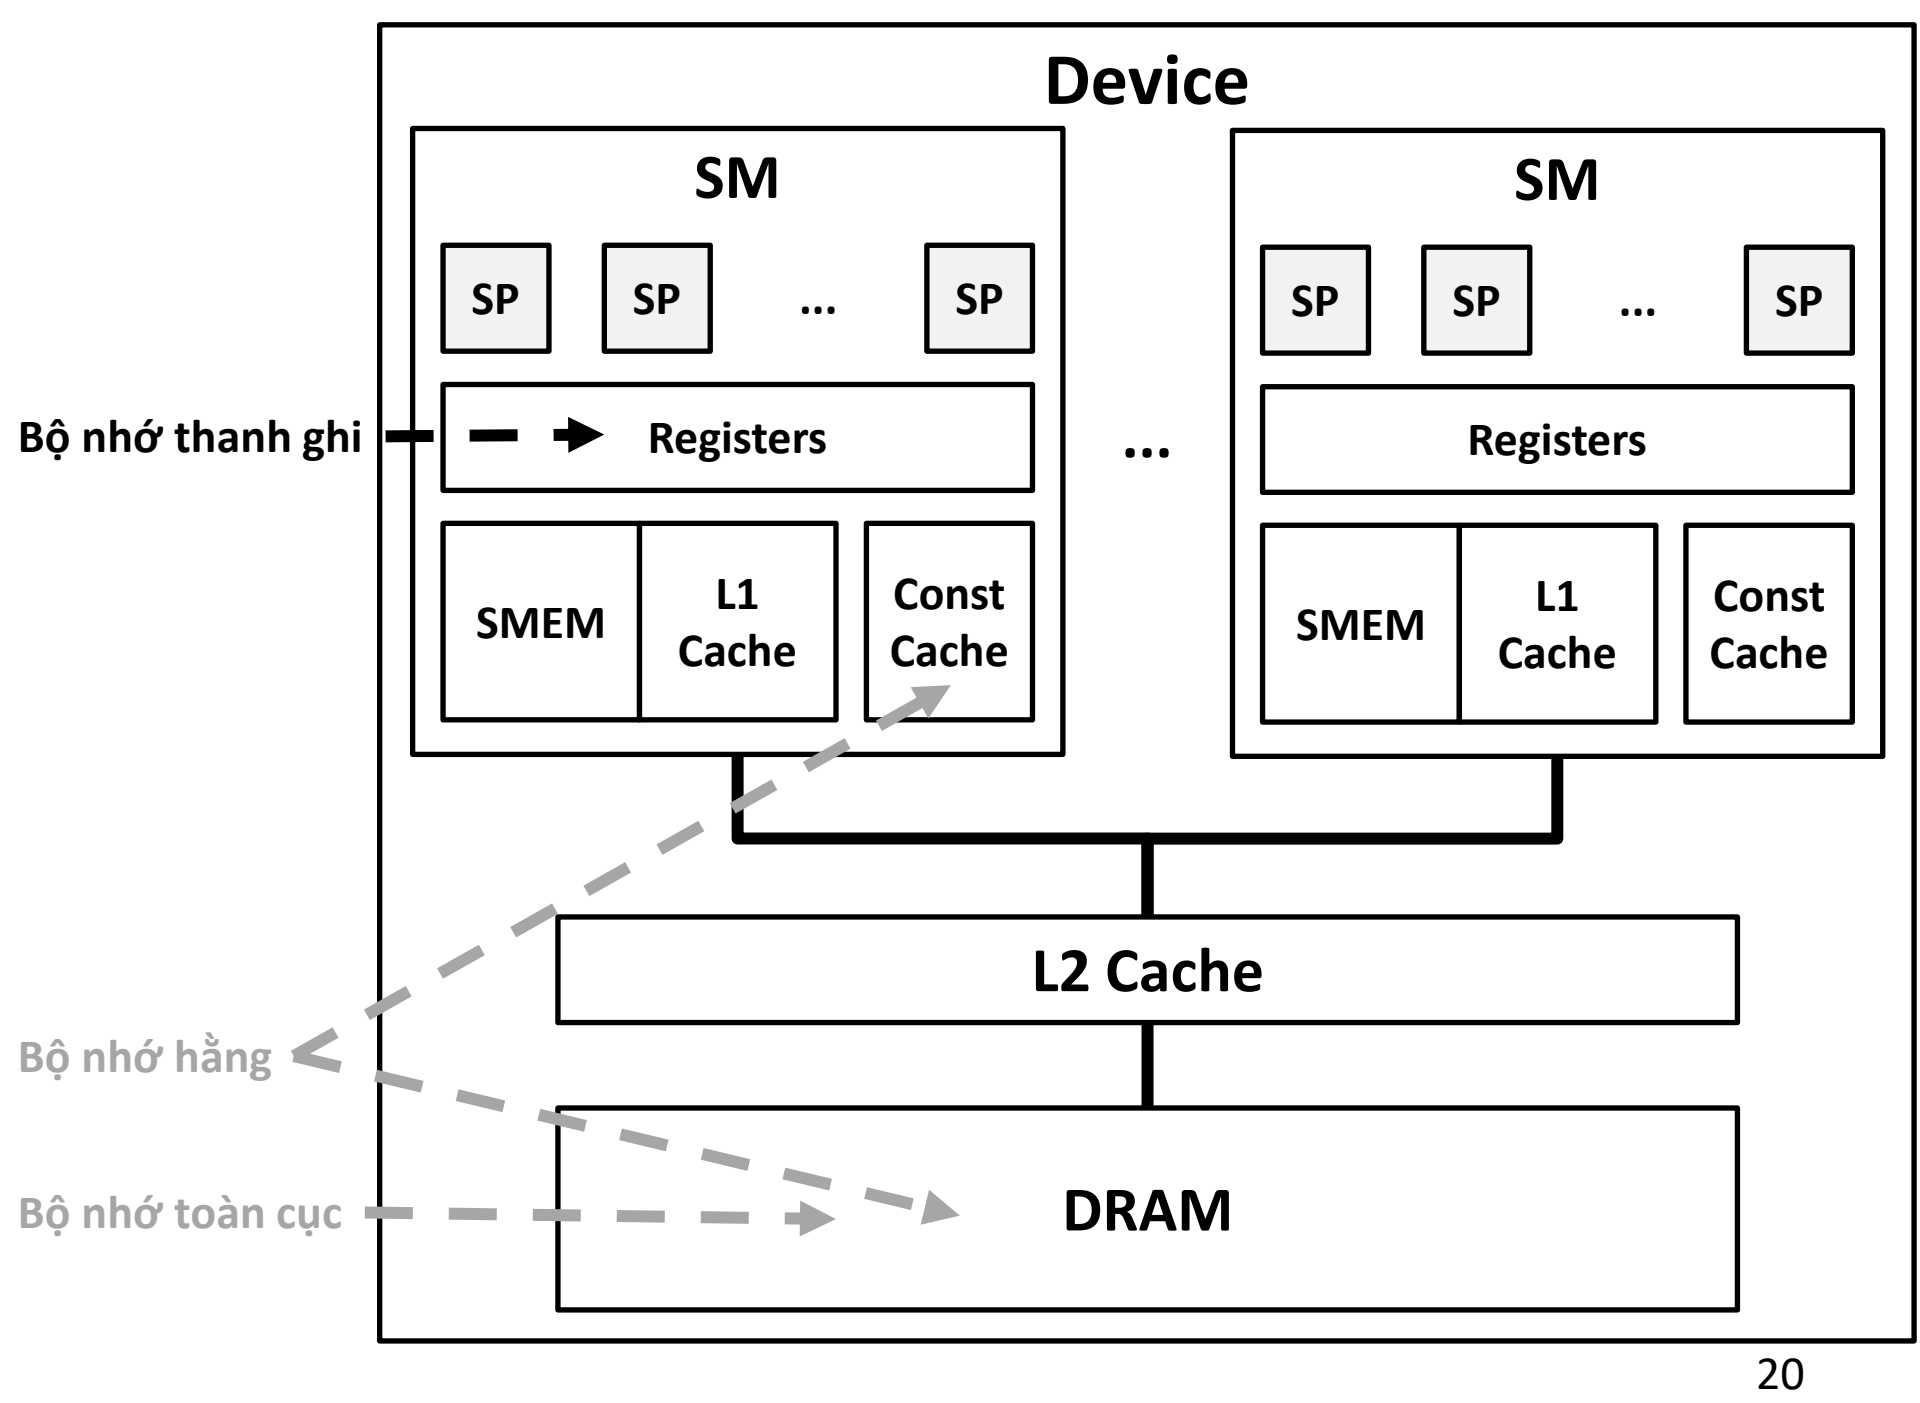
Device
SM
SP
SP
...
SP
Registers
SMEM
L1 Cache
Const Cache
SM
SP
SP
...
SP
Registers
SMEM
L1 Cache
Const Cache
Bộ nhớ thanh ghi
L2 Cache
Bộ nhớ hằng
Bộ nhớ toàn cục
DRAM

Bộ nhớ thanh ghi (RMEM)

Ngoài CMEM với cơ chế cache, ta cũng có thể làm giảm số lần truy xuất DRAM bằng **bộ nhớ thanh ghi (RMEM – Registers)**

```
__global__ void convOnDevice(float *d_ir
{
    int i = blockIdx.x * blockDim.x + threa

    if (i < NO)
    {
        float s = 0;
        d_out[i] = 0;
        for (int j = 0; j < NF; j++)
        {
            s += d_flt[j] * d_in[i + j];
            d_out[i] += d_flt[j] * d_in[i + j];
        }
        d_out[i] = s;
    }
}
```

- Mỗi thread sẽ có một phiên bản riêng của biến s và được lưu ở RMEM của thread đó
- RMEM là bộ nhớ có tốc độ truy xuất nhanh nhất ở device
- RMEM của thread sẽ được giải phóng khi thread thực thi xong hàm kernel
- Host không thể "thấy" và đọc/ghi RMEM

Ghi kết quả **nhiều lần** xuống RMEM

Ghi kết quả cuối cùng **một lần** từ RMEM xuống GMEM

Bộ nhớ cục bộ (LMEM)

- Tuy có tốc độ nhanh nhất, nhưng RMEM có dung lượng khá hạn chế
  - Ở hầu hết các CC: 64K thanh ghi 32-bit / SM, tối đa 255 thanh ghi 32-bit / thread
- Nếu mỗi thread có lượng dữ liệu lớn hơn dung lượng RMEM cho phép thì sao?
  - "Tràn" RMEM, dữ liệu bị tràn sẽ được đẩy xuống **bộ nhớ cục bộ (LMEM – local memory)**
  - LMEM nằm ở DRAM, nhưng có cơ chế cache

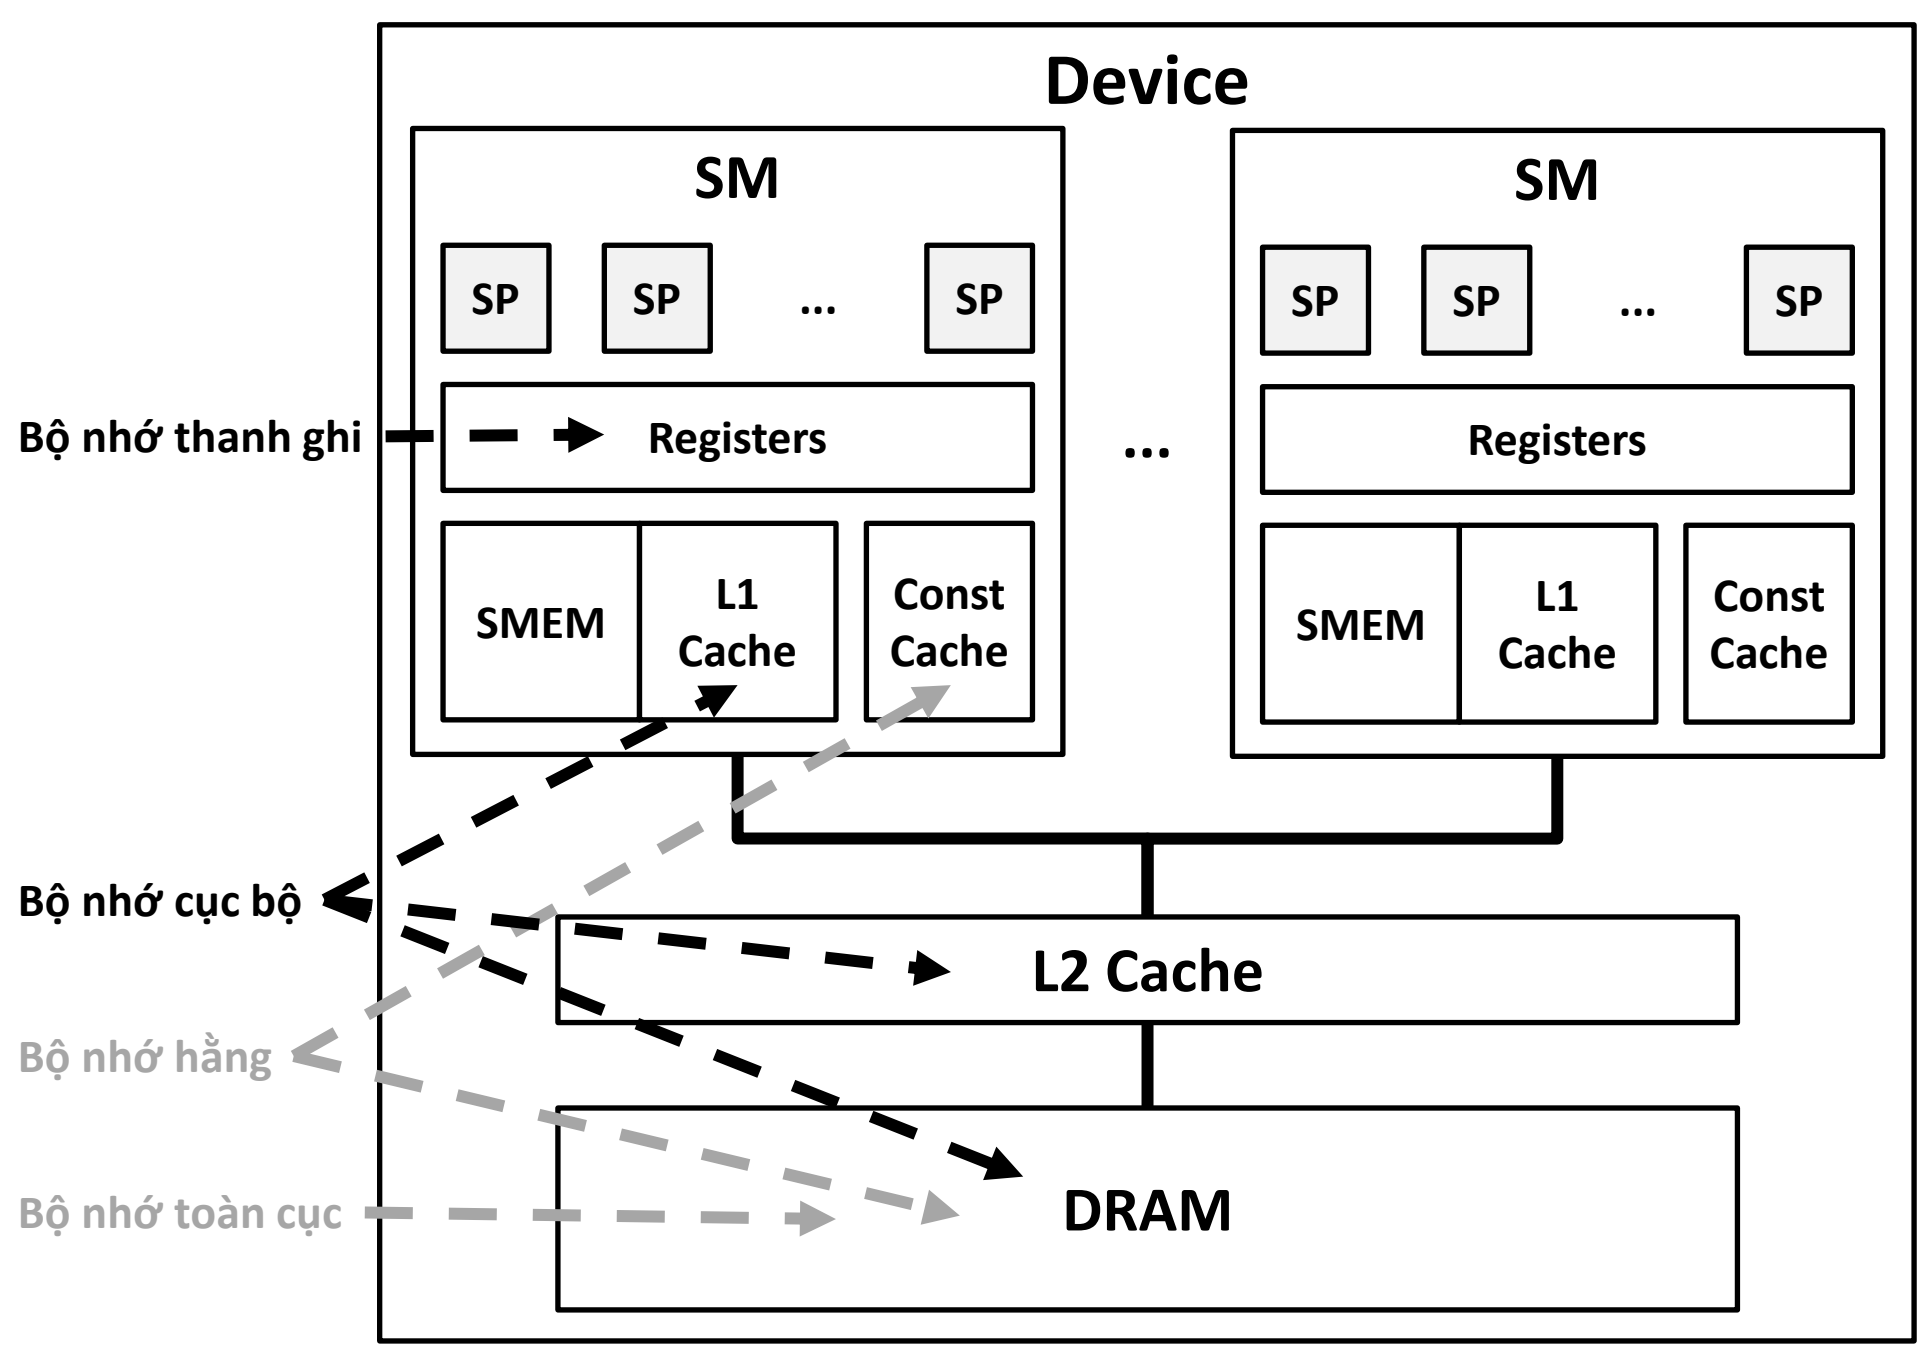
Device
SM
SP
SP
...
SP
Registers
SMEM
L1 Cache
Const Cache
SM
SP
SP
...
SP
Registers
SMEM
L1 Cache
Const Cache
...
Bộ nhớ thanh ghi
Bộ nhớ cục bộ
L2 Cache
Bộ nhớ hằng
Bộ nhớ toàn cục
DRAM

Bộ nhớ cục bộ (LMEM)

- Tuy có tốc độ nhanh nhất, nhưng RMEM có dung lượng khá hạn chế
  - Ở hầu hết các CC: 64K thanh ghi / SM, tối đa 255 thanh ghi / thread
- Nếu mỗi thread có lượng dữ liệu lớn hơn dung lượng RMEM cho phép thì sao?
  - "Tràn" RMEM, dữ liệu bị tràn sẽ được đẩy xuống **bộ nhớ cục bộ (LMEM – local memory)**
  - LMEM nằm ở DRAM, nhưng có cơ chế cache
  - Giống RMEM, LMEM là dành riêng cho mỗi thread và sẽ được giải phóng khi thread thực thi xong

Bộ nhớ chia sẻ (SMEM)

- Ngoài CMEM và RMEM, ta cũng có thể làm giảm số lần truy xuất DRAM bằng **bộ nhớ chia sẻ (SMEM – shared memory)**
- Mỗi block sẽ có một SMEM riêng và sẽ được giải phóng khi block thực thi xong
- SMEM nằm ở trên các SM, cùng cấp với L1 Cache và Const Cache → có tốc độ truy xuất nhanh hơn nhiều so với DRAM (mặc dù không bằng RMEM)

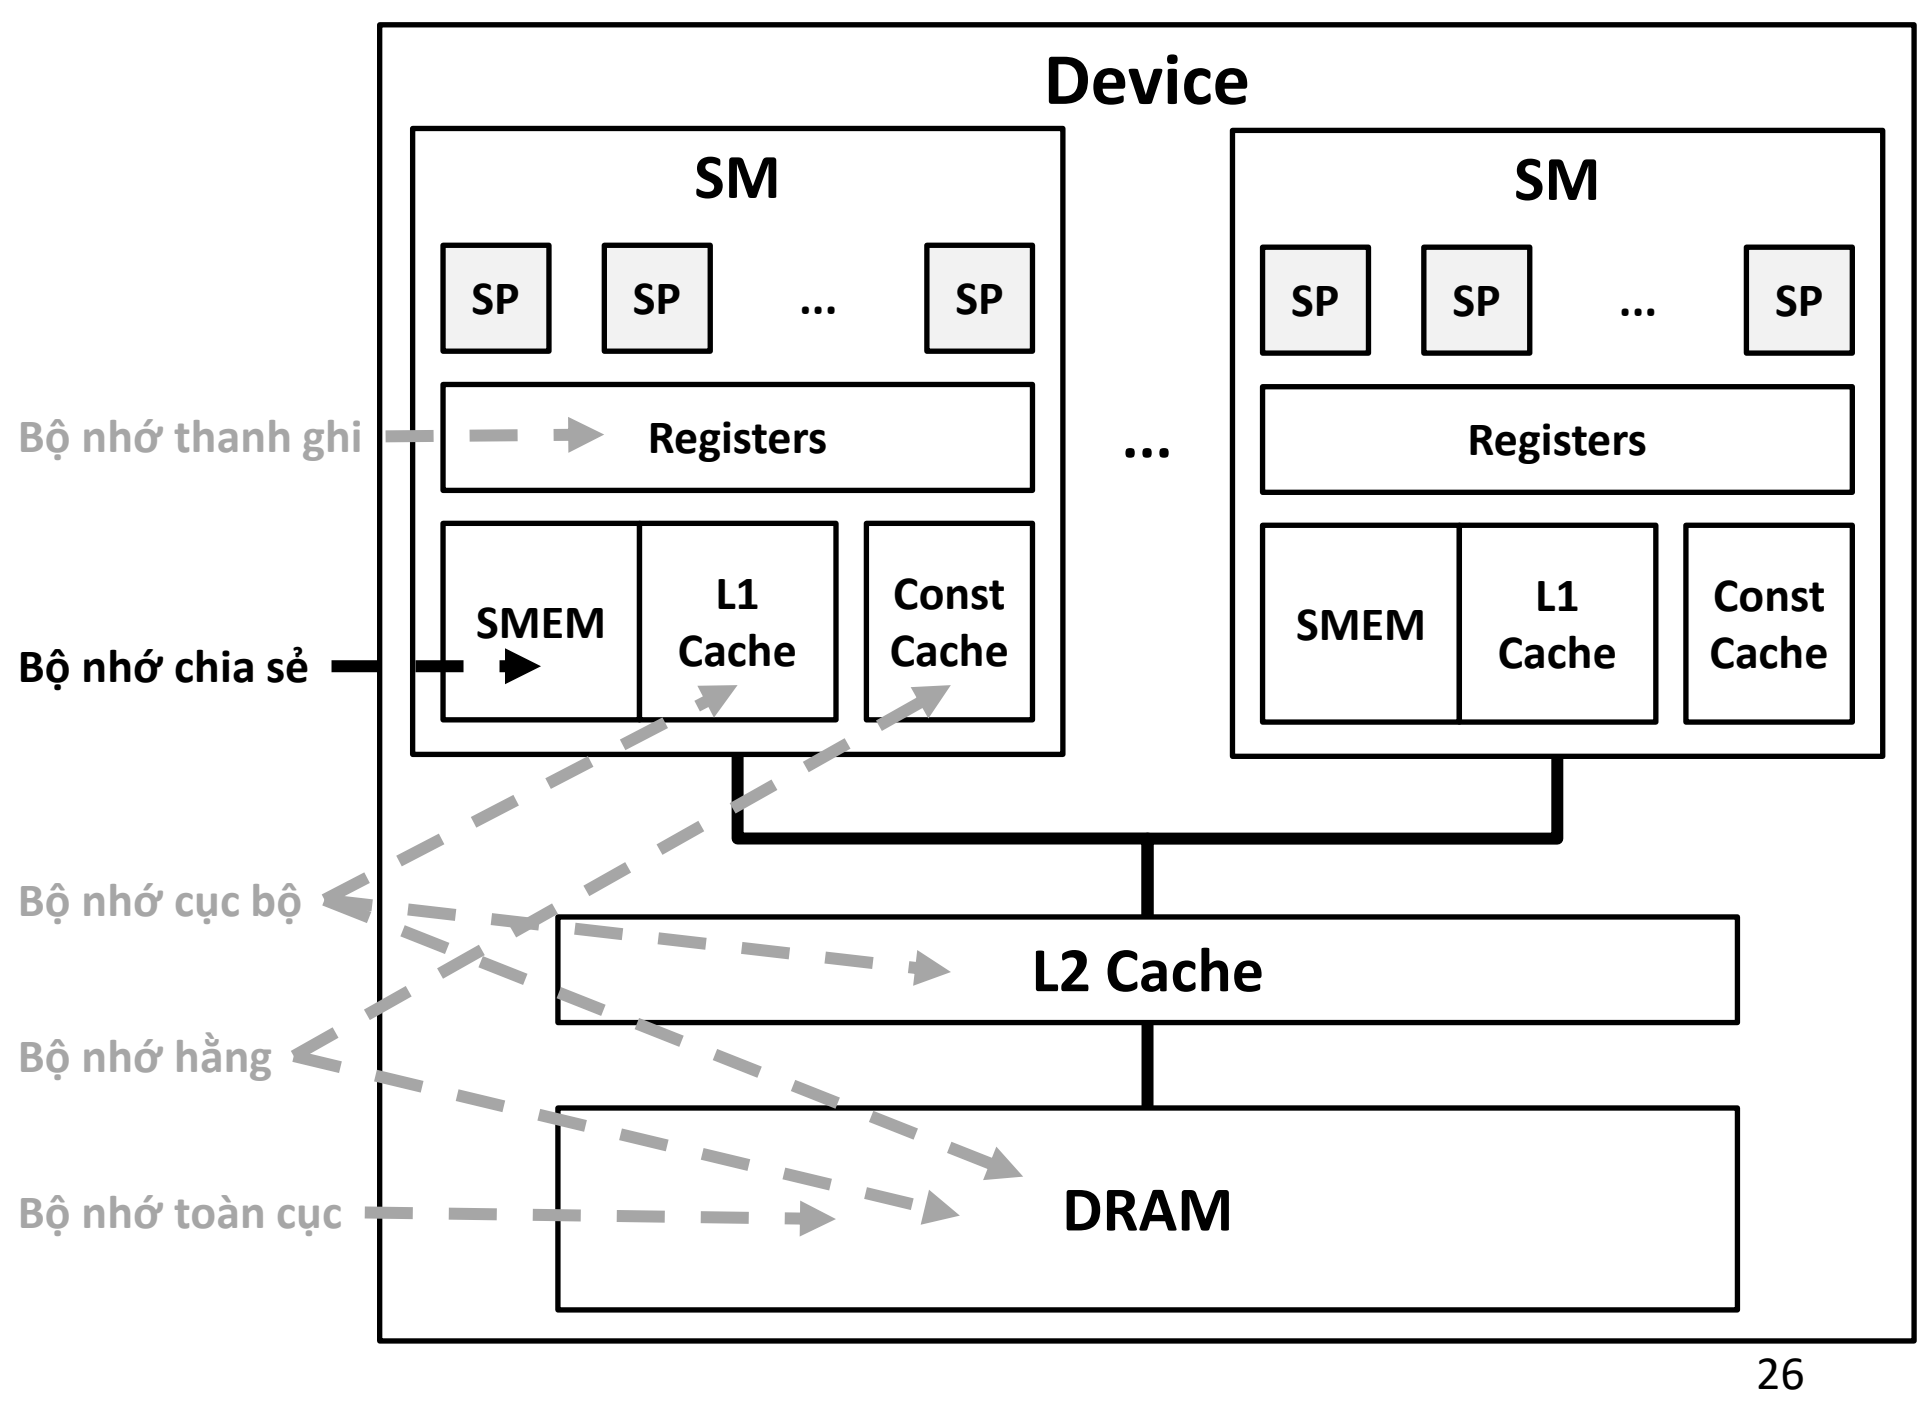
Device
SM
SP
SP
...
SP
Registers
SMEM
L1 Cache
Const Cache
SM
SP
SP
...
SP
Registers
SMEM
L1 Cache
Const Cache
...
Bộ nhớ thanh ghi
Bộ nhớ chia sẻ
Bộ nhớ cục bộ
L2 Cache
Bộ nhớ hằng
Bộ nhớ toàn cục
DRAM

Bộ nhớ chia sẻ (SMEM)

- Ngoài CMEM và RMEM, ta cũng có thể làm giảm số lần truy xuất DRAM bằng **bộ nhớ chia sẻ (SMEM – shared memory)**
- Mỗi block sẽ có một SMEM riêng và sẽ được giải phóng khi block thực thi xong
- SMEM nằm ở trên các SM, cùng cấp với L1 Cache và Const Cache → có tốc độ truy xuất nhanh hơn nhiều so với DRAM (mặc dù không bằng RMEM)
- Ở hầu hết các CC, mỗi SM có 48-96 KB SMEM và 48 - 96 KB này được phân ra cho các block chứa trong SM
- Là "bộ nhớ cache" mà người lập trình có thể kiểm soát được
- Host không thể đọc/ghi SMEM

Ví dụ 1: bài toán "reduction"

Xét 1 block gồm 4 thread

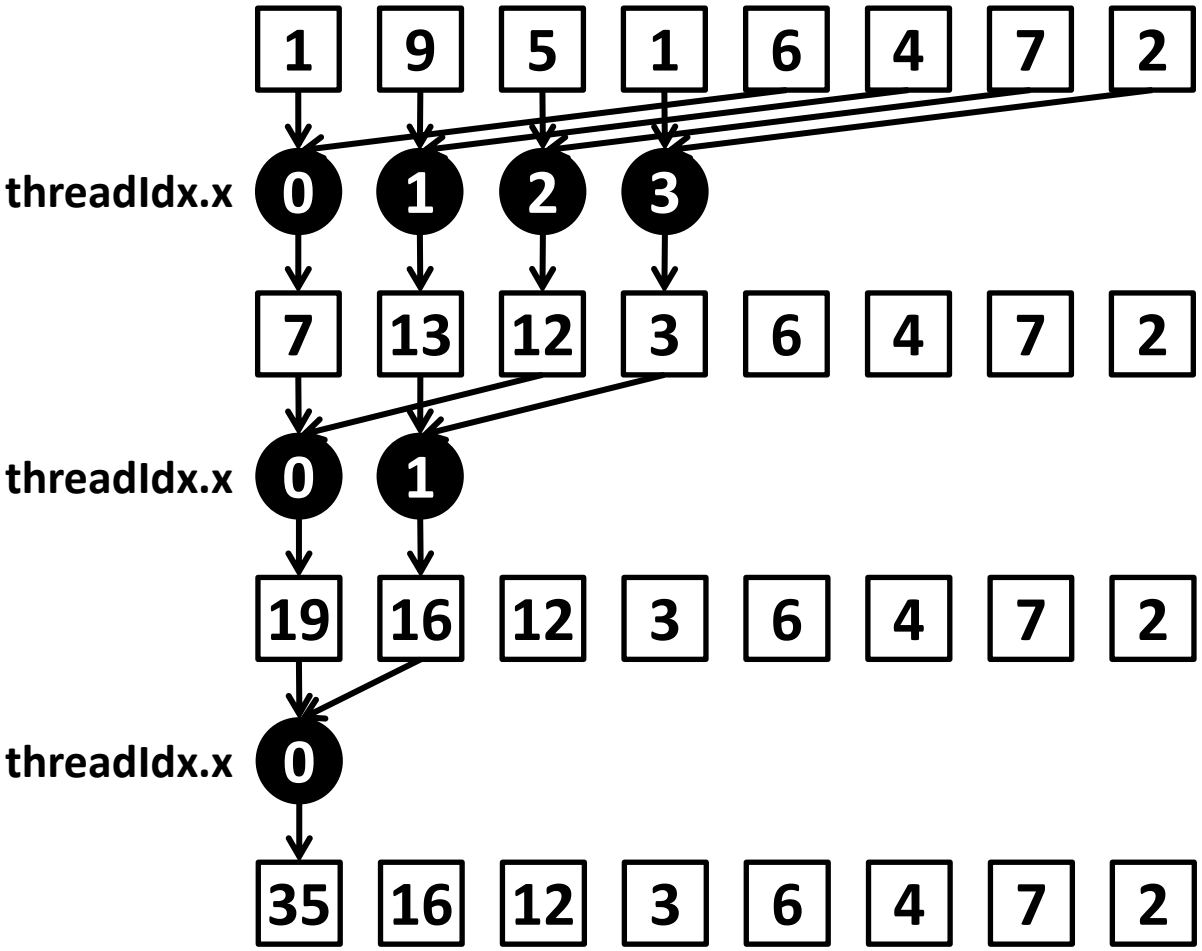

Ý tưởng. Thay vì ở mỗi bước block đều phải đọc ghi DRAM, block sẽ:

- Đọc một lần dữ liệu của block từ GMEM vào SMEM
- Ở mỗi bước, block đọc ghi với dữ liệu trên SMEM
- Cuối cùng, block ghi kết quả từ SMEM xuống GMEM

```
__global__ void reduceOnDevice4(int *in, int *out, int n)
{
   // Each block loads data from GMEM to SMEM
   __shared__ int blkData[2 * 256];
   int numElemsBeforeBlk = blockIdx.x * blockDim.x * 2;
   blkData[ ? ] = in[ ? ];
   blkData[ ? ] = in[ ? ];
   __syncthreads();

   // Each block does reduction with data on SMEM
   for (int stride = blockDim.x; stride > 0; stride /= 2)
   {
      if (threadIdx.x < stride)
      {
         blkData[ ? ] += blkData[ ? ];
      }
      __syncthreads(); // Synchronize within block
   }

   // Each block writes result from SMEM to GMEM
   if (threadIdx.x == 0)
      out[blockIdx.x] = blkData[ ? ];
}
```

Giả sử:

- $2*blockDim.x = 2^k$
- N chia hết cho 2*blockDim.x

Giả sử blockDim.x = 256

```
__global__ void reduceOnDevice4(int *in, int *out, int n)
{
   // Each block loads data from GMEM to SMEM
   __shared__ int blkData[2 * 256];
   int numElemsBeforeBlk = blockIdx.x * blockDim.x * 2;
   blkData[threadIdx.x] = in[numElemsBeforeBlk + threadIdx.x];
   blkData[blockDim.x + threadIdx.x] = in[numElemsBeforeBlk + blockDim.x + threadIdx.x];
   __syncthreads();

   // Each block does reduction with data on SMEM
   for (int stride = blockDim.x; stride > 0; stride /= 2)
   {
      if (threadIdx.x < stride)
      {
         blkData[ ? ] += blkData[ ? ];
      }
      __syncthreads(); // Synchronize within block
   }

   // Each block writes result from SMEM to GMEM
   if (threadIdx.x == 0)
      out[blockIdx.x] = blkData[ ? ];
}
```

Giả sử:

- $2*blockDim.x = 2^k$
- N chia hết cho 2*blockDim.x

Giả sử blockDim.x = 256

```
__global__ void reduceOnDevice4(int *in, int *out, int n)
{
   // Each block loads data from GMEM to SMEM
   __shared__ int blkData[2 * 256];
   int numElemsBeforeBlk = blockIdx.x * blockDim.x * 2;
   blkData[threadIdx.x] = in[numElemsBeforeBlk + threadIdx.x];
   blkData[blockDim.x + threadIdx.x] = in[numElemsBeforeBlk + blockDim.x + threadIdx.x];
   __syncthreads();

   // Each block does reduction with data on SMEM
   for (int stride = blockDim.x; stride > 0; stride /= 2)
   {
      if (threadIdx.x < stride)
      {
         blkData[threadIdx.x] += blkData[threadIdx.x + stride];
      }
      __syncthreads(); // Synchronize within block
   }

   // Each block writes result from SMEM to GMEM
   if (threadIdx.x == 0)
      out[blockIdx.x] = blkData[ ? ];
}
```

Giả sử:

- $2*blockDim.x = 2^k$
- N chia hết cho 2*blockDim.x

Giả sử blockDim.x = 256

```
__global__ void reduceOnDevice4(int *in, int *out, int n)
{
   // Each block loads data from GMEM to SMEM
   __shared__ int blkData[2 * 256];
   int numElemsBeforeBlk = blockIdx.x * blockDim.x * 2;
   blkData[threadIdx.x] = in[numElemsBeforeBlk + threadIdx.x];
   blkData[blockDim.x + threadIdx.x] = in[numElemsBeforeBlk + blockDim.x + threadIdx.x];
   __syncthreads();

   // Each block does reduction with data on SMEM
   for (int stride = blockDim.x; stride > 0; stride /= 2)
   {
      if (threadIdx.x < stride)
      {
         blkData[threadIdx.x] += blkData[threadIdx.x + stride];
      }
      __syncthreads(); // Synchronize within block
   }

   // Each block writes result from SMEM to GMEM
   if (threadIdx.x == 0)
      out[blockIdx.x] = blkData[0];
}
```

Giả sử:
- $2*blockDim.x = 2^k$
- N chia hết cho 2*blockDim.x

Giả sử blockDim.x = 256

```
__global__ void reduceOnDevice4(int *in, int *out, int n)
{
   // Each block loads data from GMEM to SMEM
   __shared__ int blkData[2 * 256];
   int numElemsBeforeBlk = blockIdx.x * blockDim.x * 2;
   blkData[threadIdx.x] = in[numElemsBeforeBlk + threadIdx.x];
   blkData[blockDim.x + threadIdx.x] = in[numElemsBeforeBlk + blockDim.x + threadIdx.x];
   __syncthreads();

   // Each block does reduction with data on SMEM
   for (int stride = blockDim.x; stride > 0; stride /= 2)
   {
      if (threadIdx.x < stride)
      {
         blkData[threadIdx.x] += blkData[threadIdx.x + stride];
      }
      __syncthreads(); // Synchronize within block
   }

   // Each block writes result from SMEM to GMEM
   if (threadIdx.x == 0)
      out[blockIdx.x] = blkData[0];
}
```

Giả sử:
- $2*blockDim.x = 2^k$
- N chia hết cho 2*blockDim.x

Giả sử blockDim.x = 256

Bỏ đi được không?

Thí nghiệm

Function	Kernel time (ms)
reduceOnDevice1	6.937
reduceOnDevice2	4.968
reduceOnDevice3	4.250
reduceOnDevice4	3.029

Ví dụ 2: bài toán tính tích chập một chiều

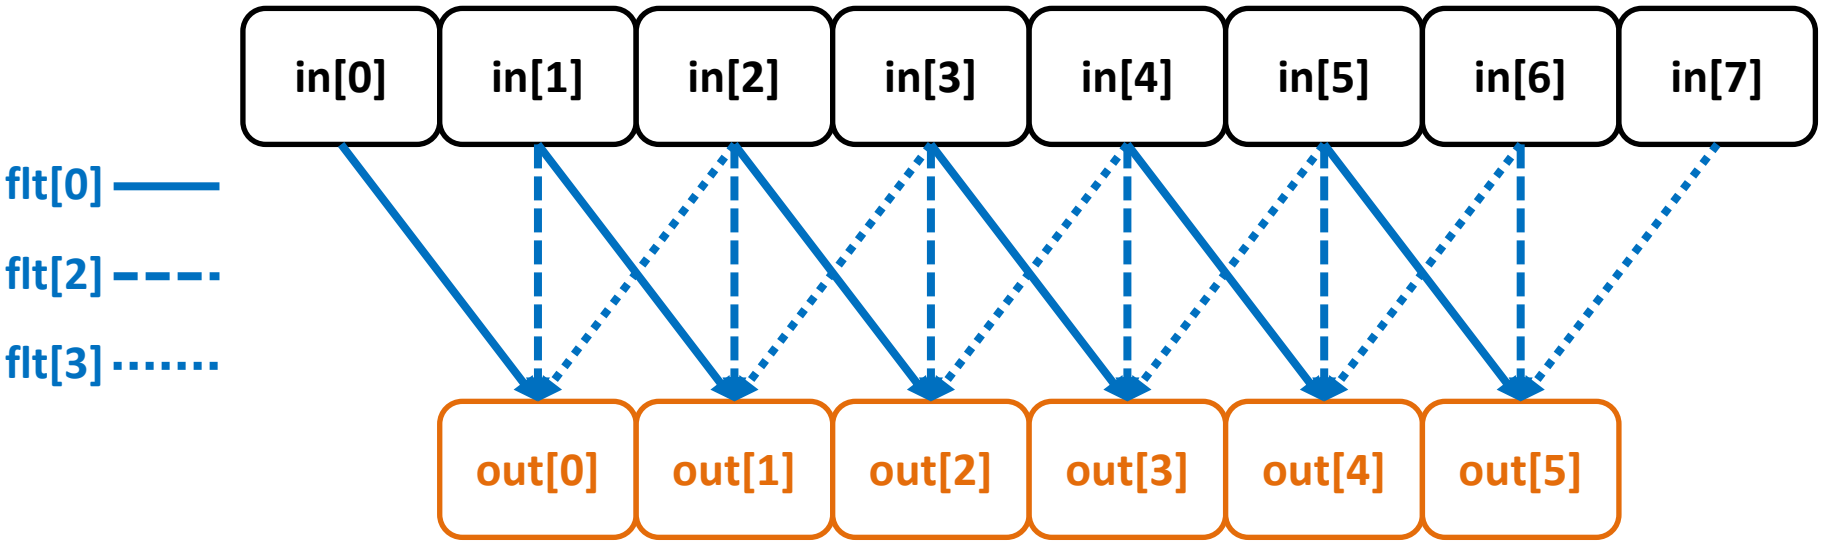

Ta thấy mỗi phần tử `in[i]` được dùng chung cho 3 thread cạnh nhau
→ Mỗi block đọc dữ liệu của mình từ GMEM vào SMEM (mỗi phần tử ở GMEM được đọc một lần); sau đó, dữ liệu ở SMEM này được dùng lại nhiều lần cho các thread trong block

Ví dụ 2: bài toán tính tích chập một chiều

Code: HW3 ☺

Tổng kết

Tận dụng các bộ nhớ có tốc độ cao để giảm số lần truy xuất xuống DRAM

Giá phải trả: có thể sẽ làm occupancy giảm xuống (Vd, nếu SM có 48 KB SMEM và block dùng đến 40 KB SMEM thì trong SM chỉ có thể chứa được một block)

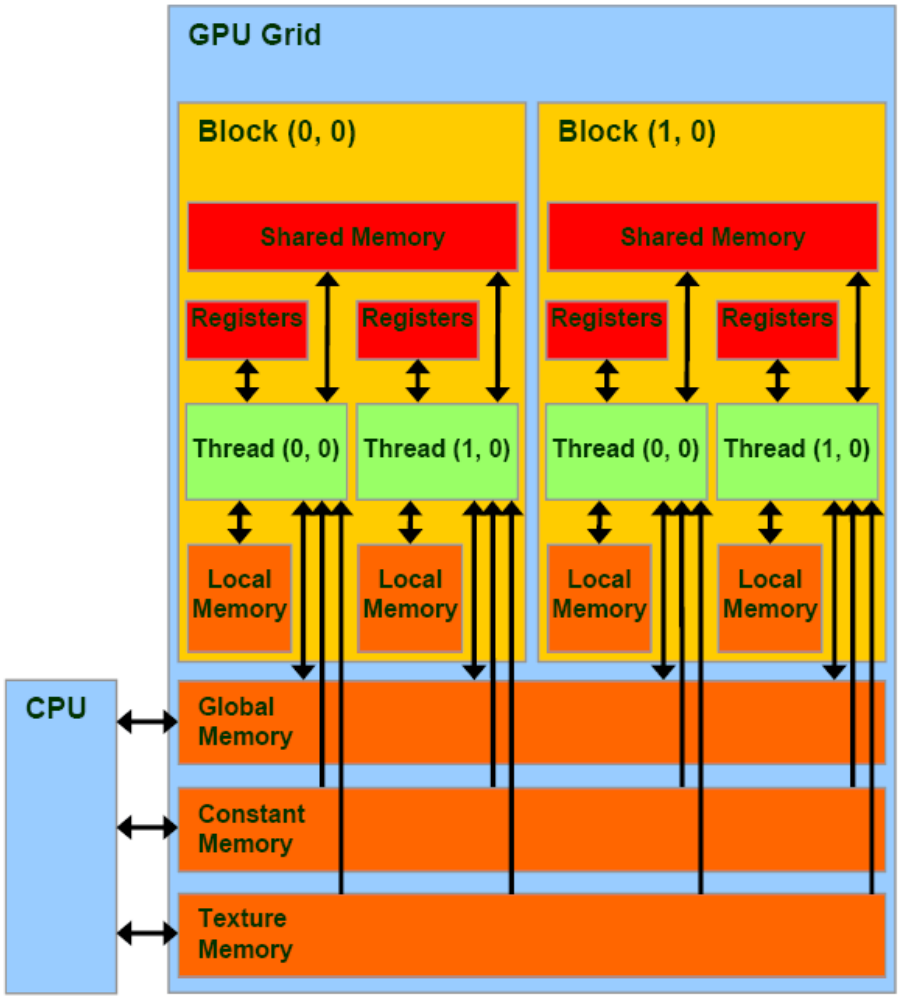

Nguồn ảnh: http://www.realworldtech.com/includes/images/articles/g100-2.gif

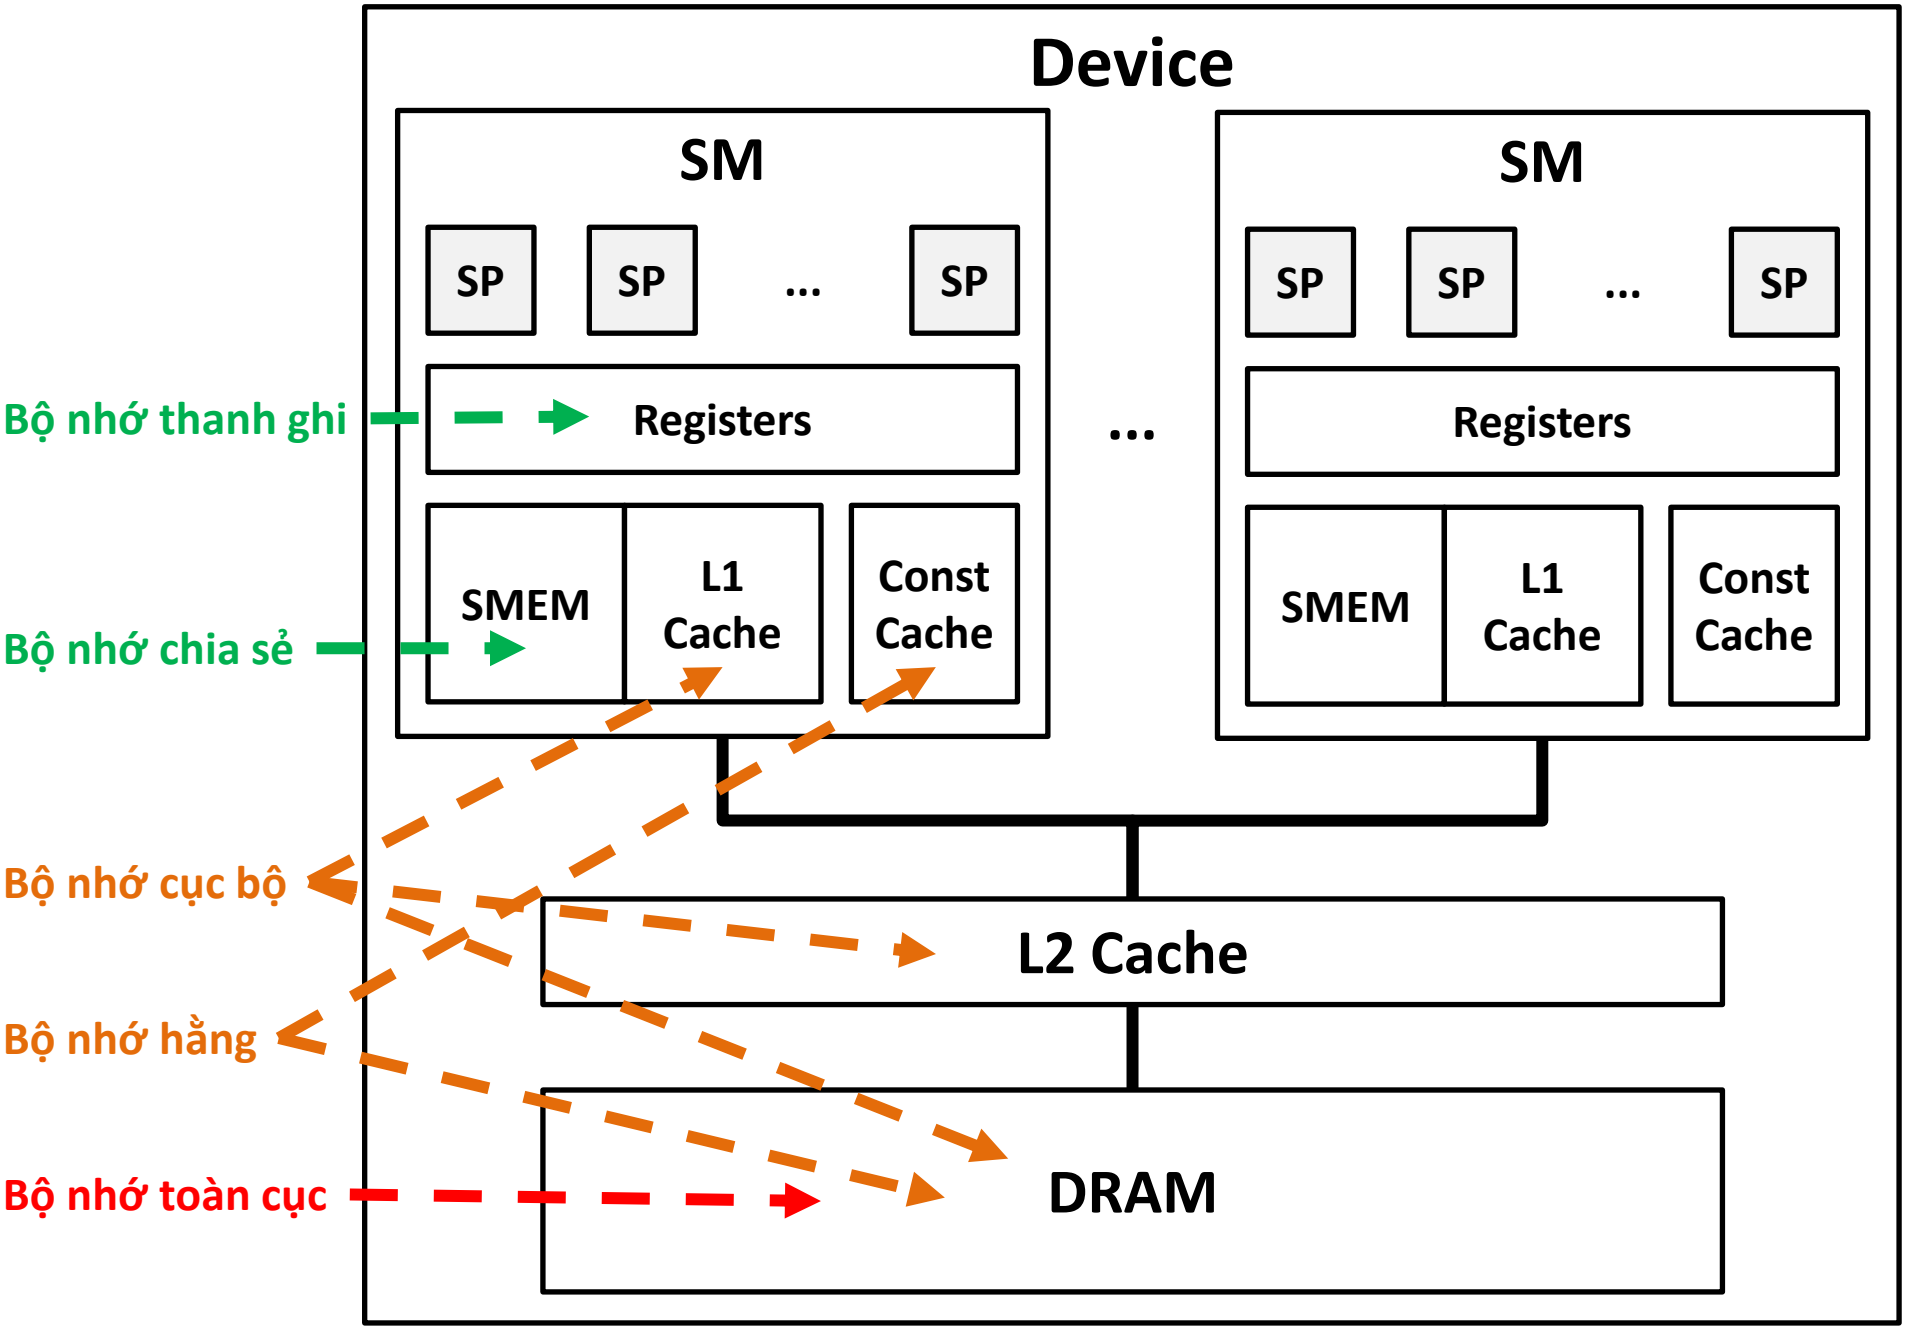
Device
SM
SP
SP
...
SP
Registers
SMEM
L1 Cache
Const Cache
SM
SP
SP
...
SP
Registers
SMEM
L1 Cache
Const Cache
...
Bộ nhớ thanh ghi
Bộ nhớ chia sẻ
Bộ nhớ cục bộ
Bộ nhớ hằng
Bộ nhớ toàn cục
L2 Cache
DRAM